

Relatorio tecnico - parte 1

Relatorio tecnico - Tech Challenge B Problema escolhido O dataset analisado e o arquivo anexado data.csv, localizado em data.csv. A tarefa foi formulada como um problema de classificacao binaria: prever se um caso deve ser marcado como Dangerous = Yes ou Dangerous = No a partir do animal e de cinco sintomas observados. Embora o enunciado use exemplos de diagnostico humano, este dataset representa um cenario clinico/veterinario de triagem. A solucao deve ser interpretada como apoio inicial a decisao, nunca como diagnostico final automatico.

Exploracao dos dados - Linhas originais: 871 - Linhas apos limpeza: 841 - Duplicatas removidas: 28 - Colunas: AnimalName, symptoms1, symptoms2, symptoms3, symptoms4, symptoms5, Dangerous - Distribuicao do alvo: {'yes': 821, 'no': 20} Foram gerados graficos de distribuicao do alvo, animais mais frequentes, sintomas mais frequentes, features numericas derivadas e valores ausentes.

Pre-processamento As estrategias utilizadas foram: - padronizacao de texto com strip, caixa baixa e normalizacao de espacos; - correcao de algumas inconsistencias textuais evidentes, como seizuers para seizures; - remocao de duplicatas; - mapeamento de Dangerous para alvo binario; - preenchimento de sintomas ausentes com unknown; - criacao de features numericas derivadas: quantidade de sintomas unicos, quantidade de sintomas desconhecidos e tamanho textual dos sintomas; - OneHotEncoder para variaveis categoricas; - StandardScaler para features numericas; - pipeline do scikit-learn para evitar vazamento de dados entre treino, validacao e teste.

Correlacao A correlacao foi calculada de duas formas: - correlacao de Pearson entre dummies one-hot e o alvo binario; - Cramer's V entre cada variavel categorica original e o alvo. Essas tabelas foram salvas em tables/encoded_feature_correlations.csv e tables/categorical_association_cramers_v.csv.

Modelagem Foram treinados quatro modelos, cobrindo tecnicas lineares, arvores e metodos baseados em vizinhanca: - Regressao Logistica; - Arvore de Decisao; - Random Forest; - KNN. A separacao foi feita em treino, validacao e teste. O conjunto de validacao foi usado para escolher o melhor modelo, priorizando recall da classe Yes, pois em triagem clinica e mais grave deixar de sinalizar um caso perigoso do que gerar um alerta falso. O F1-score foi usado como criterio de equilibrio.

Metricas de validacao

	model	accuracy	precision_yes	recall_yes	f1_yes	f1_weighted	roc_auc
	knn	0.9762	0.9762	1.0000	0.9880	0.9644	0.8369
	random_forest	0.9821	0.9879	0.9939	0.9909	0.9809	0.9268
	logistic_regression	0.9702	0.9818	0.9878	0.9848	0.9682	0.9070
	decision_tree	0.9107	0.9934	0.9146	0.9524	0.9365	0.8567

Modelo selecionado: knn.

Metricas do modelo selecionado

	dataset	accuracy	precision_yes	recall_yes	f1_yes	f1_weighted	roc_auc
	train	1.0000	1.0000	1.0000	1.0000	1.0000	1.0000
	validation	0.9762	0.9762	1.0000	0.9880	0.9644	0.8369
	test	0.9763	0.9763	1.0000	0.9880	0.9646	0.9833

Interpretacao O script gera importancia de variaveis nativa quando o modelo permite (feature_importances_ ou coeficientes). Quando isso nao esta disponivel, usa permutation importance. SHAP e executado automaticamente quando a biblioteca esta instalada e compativel com o modelo selecionado.

Status SHAP: SHAP estava instalado, mas falhou neste modelo/ambiente. Fallback mantido com feature importance. Erro: The passed model is not callable and cannot be analyzed directly with the given masker! Model: KNeighborsClassifier(n_neighbors=7, weights='distance')

Top features:

feature	importance
symptoms1	0.0020
unique_symptom_count	0.0000
symptoms2	0.0000
symptoms3	0.0000
symptoms4	0.0000
symptom_text_length	0.0000
unknown_symptom_count	0.0000
AnimalName	-0.0002
symptoms5	-0.0005

Analise critica O modelo pode ser util como ferramenta de apoio a triagem, destacando casos que merecem revisao prioritaria. Entretanto, seu uso pratico exige cuidado: - o dataset e pequeno e limitado ao universo de animais/sintomas observados; - categorias novas podem aparecer em producao;

Relatorio tecnico - parte 2

- correlacao nao implica causalidade; - sintomas textuais foram tratados como categorias, sem contexto clinico amplo; - e necessario validar o modelo com dados externos e acompanhamento de profissionais antes de qualquer uso real. Assim, a recomendacao e usar a solucao como alerta inicial e ferramenta de organizacao do fluxo de atendimento. A decisao final deve permanecer com o(a) medico(a) ou profissional responsavel. Artefatos gerados - Modelo: models/best_model.pkl - Metricas: tables/validation_metrics.csv e tables/best_model_metrics.csv - Relatorios de classificacao: tables/classification_reports.json - Exemplo de predicao: tables/prediction_example.json - README: outputs_techchallenge_b\docs\README.md - Dockerfile: outputs_techchallenge_b\docs\Dockerfile - Roteiro do video: outputs_techchallenge_b\docs\roteiro_video_demo.md Figuras - outputs_techchallenge_b\figures\01_target_distribution.png - outputs_techchallenge_b\figures\02_top_animals.png - outputs_techchallenge_b\figures\03_top_symptoms.png - outputs_techchallenge_b\figures\04_numeric_features_by_target.png - outputs_techchallenge_b\figures\05_missing_values.png - outputs_techchallenge_b\figures\06_top_correlations.png - outputs_techchallenge_b\figures\07_cramers_v.png - outputs_techchallenge_b\figures\08_confusion_matrix_train.png - outputs_techchallenge_b\figures\08_confusion_matrix_validation.png - outputs_techchallenge_b\figures\08_confusion_matrix_test.png - outputs_techchallenge_b\figures\09_feature_importance.png


Metricas do modelo selecionado

dataset	model	accuracy	precision_yes	recall_yes	f1_yes	f1_weighted	roc_auc
train	knn	1.0000	1.0000	1.0	1.000	1.0000	1.0000
validation	knn	0.9762	0.9762	1.0	0.988	0.9644	0.8369
test	knn	0.9763	0.9763	1.0	0.988	0.9646	0.9833


01 Target Distribution




02 Top Animals




03 Top Symptoms




04 Numeric Features By Target




05 Missing Values




06 Top Correlations




07 Cramers V




08 Confusion Matrix Train



08 Confusion Matrix Validation



08 Confusion Matrix Test



09 Feature Importance

